Agent 架构变革的起点 20260513

全文摘要

1、Agent 市场空间与单 Agent 发展

·Agent 演进逻辑与市场空间：Agent 架构的演进可用“打水漂”比喻阐释：行业发展会出现多个技术弹射点，首个弹射点为 OpenCloud，第二个是当前行业热点 Hermes，后续还将涌现更多技术热点，最终进入产业融合的成熟状态，把握整体发展脉络可避免在阶段性行业热潮中迷失。Hermes 的核心特性是让 Agent 具备 skill 自我进化能力，用户使用频次越高适配性越强，国内相关技术同步推进，Evenotion Map 团队正开展该领域研发，近期已推出新产品。当前 Agent 行业整体采用率偏低，2026 年行业采用率将提升至 40%；据麦肯锡预测，2030 年 Agent 领域可贡献 2.6-4.4 万亿美元经济价值，行业规模可观，蕴藏大量投资与商业机遇。IDC 观点显示，Agent 行业总规模将持续增长，发展与通信、数据、硬件等领域高度相关。

·单 Agent 架构发展方向：当前单 Agent 架构仍存在待完善问题，与大模型缺陷类似，单 Agent 有时会输出荒谬决策，存在安全漏洞，运行可靠性不足。为提升运行精确性，单 Agent 架构的技术迭代方向主要为增加状态机、规则引擎、符号推理等模块，通过混合架构解决现存缺陷。混合架构可让单 Agent 进入可审计、可追溯、有权限、有历史的稳定运行状态，可靠性大幅提升，相当

于从原来仅配置主刀医生的单一模式，升级为人员配置完整的完善手术团队。

2、单 Agent 架构核心局限性

·单 Agent 核心缺陷分析：单 Agent 架构存在多维度核心局限性，具体如下：

a. 上下文污染问题：2025 年 10 月 CloudCode 发布的技术博客显示，在 20 万行代码场景下会出现上下文注意力衰减现象，当上下文长度超过一定阈值后，会出现类似开一整天会的头昏脑胀状态，进而引发注意力分散、跳步骤漏约束、预设规则与意图冲突等问题。

b. 任务无法形成有效闭环：单 Agent 执行任务时，即便依托相关技术具备一定自我编码能力，可做到遇山开路、遇水架桥，但遇到无法突破的场景时，任务会直接被丢弃并呈现失败状态，无法形成良性循环，循环能力需开发者自行补充，目前仅为准生产级产品。

c. 可调试性极差：系统出现问题时，问题节点隐藏在模糊状态中，难以精准定位排查，调整优化难度极高。

d. 扩展断层问题：通用单 Agent 无法适配医疗、法律等专业领域的需求，架构本身拓展性存在明显不足。

e. 容错率极低：单 Agent 架构中，上游 Agent 产生的幻觉会在中下游无限放大，直接拖垮整条任务链；即便通过混合架构提升

单个 Agent 的准确率与可审计性，也无法解决单硬件本身及多硬件之间的能力缺陷问题。

3、多 Agent 生态架构与协作模式

·多 Agent 核心架构形态：多 Agent 核心架构为编排器中枢加多硬件的组合形态，是多 Agent 体系落地应用的核心基础，可弥补单 Agent 存在的性能瓶颈、上下文污染、可调试性差等固有缺陷。多硬件可呈现三种不同的协作处理方法，适配不同业务场景需求。其中第一种为分层协作模式，运行逻辑类比科室层级结构，在医疗、金融领域均有适用场景。

·多 Agent 三种协作模式：多 Agent 协作分为分层、网状、持续交接三种模式，多模态方向为技术最先突破领域：

a. 网状协作：模式类似广场，不同主体可碰撞形成可行路径、产出创意成果，更适配创意类场景。2023 年已率先实现文字、多模态技术突破，近期 GPT 推出的新图片模型也广受关注，后续有望落地由多云建能支撑的更优多模态产品。谷歌大脑一位原创始人已推出多模态产品，具备两大核心功能：一是支持对话过程随时打断，解决当前大模型输出时仅能暂停、无法实时打断的痛点；二是实现输入输出全链路多模态，当前行业内大模型已普遍实现输入多模态，该产品可进一步支持多模态输出，可生成动态 HTML 页面，终极目标是生成影片，多模态、多 AI 镜头架构是当前技术突破的核心方向。

b. 持续交接：模式为层级式流转，以东方证券用户反馈处理场景

为例，首先由客服 AI 承接用户意图，识别到对应技术问题后移交至对应部门的 Agent 拆解任务、解决问题，问题解决后将结果返回至上游客服承接模块，由其转化为用户可理解的语言反馈给用户，该模式也被称为磁吸式处理模式。

4、Agent 协议层发展与落地案例

·Agent 协议层发展现状：当前 Agent 领域尚未实现与人类生产生活环境的广泛连接，行业存在发展阶段争议，无法明确当前处于类似 1991 年 1 月的泡沫膨胀阶段还是接近 1991 年 12 月的崩溃拐点。核心原因在于协议层疏通工作仍在推进，类比古时四川原为大海，经大禹治水开凿三峡才实现水系疏通，目前工具调用层的内部调用环节中 MCP 协议已十分成熟。目前 Agent 协议层已有三类核心协议，定位与适用场景各有差异：MCP 是成熟的内部插件调用协议，相当于系统内部的插件市场，Agent 可直接调用其他主体提供的成熟插件；AtoA 是谷歌提出的 Agent 间同步对话协议，可实现两个 Agent 间的状态同步对话；ACP 为异步对话协议。三类协议可协同完成复杂需求，以采购螺丝寻找最低供货价为例：采购 Agent 首先调用 MCP 查询过往采购记录，再通过开放协议向公共领域广播需求，匹配到各电商平台的询价 Agent 并获取报价后，通过 AtoA 协议与报价最低的询价 Agent 完成一对一同步对话，即可完成全流程采购。现有协议仍存在痛点，AMP 类协议仅支持通信功能，无法解决不同 Agent 间的陌生发现、需求撮合问题。目前已有市场主体探索新的协议方案，

与 NMP 协议方、爱美客、杭州云谷展开合作，针对性解决产业链上下游各 Agent 间的对话与意图撮合问题，该方案将意图量化，可实现不同主体的意图匹配以及意图完成后的消解，但目前该方案尚处于萌芽阶段，未形成像 MCP 一样成熟的调用标准，存在较大发展机会，相关主体正在寻求融资。

·多 Agent 行业落地案例：目前多 Agent 架构已在 SaaS 领域头部大厂得到充分应用，包括 Cloud Code、GPT 相关主体在内的头部企业均已派驻驻场工程师进入传统行业推进技术落地，但当前成熟落地技术尚未开源，暂未实现全行业大范围普及，开源通用架构落地存在明确行业需求。多 Agent 技术已在四大领域实现落地，降本提效价值明确：

a. 银行金融领域：通过多节点系统可降低交易风险，减少人工处理量；

b. 电信运营商领域：可降低机器人本地算力需求，同时优化质检效率，采用事件性 AI 检测模式，AI 持续关注系统运行状态，出现异常突变时主动提醒，依托 Agent 自带的上下文、权限、身份属性，可调用对应权限主动联系相关人员处理问题，响应速度较传统模式更快；

c. 客户服务领域：可实现用户需求从意图识别到部门/工位分配再到结果返还的全流程高效处理，相较传统生硬的机器人应答模式，可降低 25%人工转接率，缩短 30%-40%回复时间，显著提升用户满意度，减少复杂问题的人工介入需求；

d. 供应链物流领域：依托多 Agent 网状协作的多节点生态，通过 Agent 自主协商的方式匹配最优运输路径，实现多货物同路线打包配送，相较传统数据库匹配模式，可降低 15%-20%运营成本。

5、Agent 技术演进核心脉络

·单 Agent 技术迭代路径：单 Agent 技术迭代沿功能补全与能力优化路径推进：早期龙虾产品内核为无记忆模块的派，仅新增记忆功能但未做分层，存在记忆混乱、任务丢失、安全性与可监测、可调试性不足的问题。后续迭代的 Hermes 实现多维度核心优化：一是落地记忆分层机制，将记忆划分为 Agent 感知外部交互环境形成的世界记忆，以及 Agent 自身交互过程中产生的主观记忆；二是支持 skill 在任务完成过程中自我迭代沉淀，早期 skill 均为提前预制的"预制菜"模式，存在 skill 中毒（故意诱导的错误 skill）、来源不明易引发系统混乱崩溃的问题，对此 CloudCode 推出了针对 8 万余个 skill 的评分系统，有效解决 skill 来源不可靠的隐患。此外 Hermes 新增反思功能，与用户交互结束后，Agent 仍可在世界知识范畴内异步探索更优解决方案，实现技能持续精进，最终达到类似自然呼吸的熟练应用状态。

·多 Agent 演进的必要性：单 Agent 架构存在固有缺陷，仅能覆盖简单通用需求，无法支撑复杂精确任务，需向多 Agent 团队化形态演进。当前通用架构的单 Agent 缺乏垂直领域专属技能与知识储备，容错性薄弱，类比单一内科医生开设的个体诊所，仅能

处理输液、售卖感冒药等简单通用需求，无法完成复杂手术这类对专业性、精确度要求极高的任务，这是单 Agent 架构层面的固有瓶颈。因此技术演进方向指向多 Agent 协作生态，类比从个体诊所升级为专科医院、三甲医院的逻辑，由不同角色、定位的 Agent 组成协作团队，各自承担对应领域专业任务，共同完成复杂高精确度的场景需求，从根本上弥补单 Agent 的能力短板。

6、大厂布局与资本押注方向

·科技大厂核心布局：科技大厂在多智能体协作网络领域已开展多项探索实践，微软于会议召开 3 天前推出 Agent 365，明确云桌面环境下 Agent 的启动、运行、结束规则，云桌面 Agent 队列与本地桌面队列互为镜像。LangChain 推出的 LangGraph 是多智能体编排器的雏形，具备类规则大脑功能，可完整记录 Agent 间任务授权、问题解决、结果返还的全流程，类似人类工作授权逻辑，可为多智能体系统提供清晰的权限、日志与历史记录支撑，有效提升系统可审计性。

·行业投资轮次与机会：当前多智能体行业投资处于硬件层优先受益阶段，“卖铲子”的硬件厂商是当前核心受益方，代表厂商如英伟达；黄仁勋是本轮 AI 浪潮的最大获益者，其手持充沛现金反向持股多家大模型厂商，还前瞻性收购玻璃厂，底层逻辑是多智能体系统运行需海量互联互通数据传输，原有铜线产能与传输能力无法支撑巨量需求，玻璃可用于生产光纤，是核心通信基础设施原材料。当前行业正处于平台层机会窗口期，已有多方布局

token 调用入口相关中转站项目，平台层核心机会集中在 token 调用入口、数据要素等赛道，待核心生产要素完全明确后，应用层机会将逐步显现。

·头部机构押注方向：头部创投机构在多智能体领域的押注方向各有侧重：a. 红杉聚焦 500 强巨头未覆盖的垂直细分赛道，重点布局金融、医疗、供应链、客服等领域的 Agent 项目，采用 MAD 护城河框架评估项目，其中 M 指优先拿下目标市场，A 指保障 Agent 的可调试性、可审计性，避免架构迭代时数据混乱难以适配新架构，D 指以快速迭代能力紧跟技术变化，做随技术浪潮上浮的“船”而非被淹没的“柱子”；b. a16z 侧重布局基础设施与编排平台赛道，相关项目关联硬件、数据及美股上市企业，可直接落地投资动作，建议基金经理重点关注该方向；c. YC 采用批量孵化模式，重点布局消费级 Agent 项目，通过大量试错筛选优质标的。

7、成熟 Agent 架构核心特征

·成熟架构核心特性：成熟 Agent 架构具备编排层、多端协作、开放协议、友好开发体验、动态化五大核心特征。各特征核心要求与作用如下：

a. 清晰编排层：承担调度、状态管理职能，核心作用是为任务失败兜底，避免任务出问题后直接停滞。

b. 原生多端协作支持：微软推出的 AutoGen 在 2025 年 12 月

推出第二个版本后即停更，核心问题是其串联式架构会逐级放大上游 Agent 的信息偏差，属于拼凑式架构；成熟架构为广场式意图串联模式，在编排器统一管控下，多 Agent 可开展多轮分析沟通与观点攻防，基于同一数据源形成共识，避免偏差传导。

c. 开放协议绑定：当前多数 NG 架构采用内部 MCP 协议实现插件调用，仅支持内部生态资源调取，未实现 Agent 生态内的开放陌生发现与交易撮合，该能力可充分释放网络效应，是未来核心发展方向。

d. 优秀开发者体验：成熟工具需具备低调用门槛特性，当前 LangGraph 虽接近相关要求，但因属于 LangChain 产品系列，开发体验不足，且未开源，可观测性存在短板。

e. Agent 动态化：Agent 的技能需具备动态迭代能力，例如 Hermes 的 skill 可通过后台双队列开展强化学习优化能力；同时需配套企业级规则管控 Agent 的启停时机，避免其过度调用服务器、设备权限或常驻进程，实现 AI 进程动态调度。

·行业发展节点判断：Agent 行业“从零到一”节点为技术与人类生产生活完全融合的时刻，当前仍处于技术积累阶段。当成熟 Agent 架构的五大核心特征全部落地，即架构完全与人类生产生活场景融合、达到"与水面齐平"的状态时，即为行业发展的"从零到一"核心节点，标志着 AIGC 领域完成从无到有的核心突破。当前技术仍处于演进过程中，判定行业迈入成熟节点的核心信号尚未出现，相关架构尚未达到全场景融合要求，行业整体处于向通

用架构演进的技术积累阶段，目前仅完成"从零到零点一"的前期探索，下一个阶段为产品化。

8、Agent 行业核心问题答疑

·多 Agent 对算力通信的需求：多 Agent 架构落地将对计算、存储、通信等基础设施产生显著增量需求，其中通信需求增长尤为突出，不同 Agent 之间需频繁传递状态等交互信息，该需求逻辑与黄仁勋收购玻璃厂的布局逻辑一致，将直接带动通信、硬件及芯片加速相关领域需求扩容。从实际落地场景看，为百人规模企业搭建多 Agent 客户服务矩阵，需采购部署多类核心基础设施：一是云上 GPU 实例，可选用亚马逊、微软等厂商的云 GPU 服务；二是事件总线、向量检索工具，其中向量检索可实现 Agent 实时记忆功能；三是边缘计算节点支撑分布式运算。上述需求将推动下游客户对云厂商、英伟达等云端加速器厂商、消息及数据厂商产生持续采购与集成需求，多 Agent 架构将带动云 GPU、事件总线、向量检索、边缘计算等基础设施需求大幅增长。

·技术演进路径与创新主体：Agent 技术演进为渐进式路径，编排加多 Agent 架构与此前的 OpenCloud、Hermes 等阶段性技术弹射点为渐进发展关系，不会出现完全替代原有技术路线的情况。技术将在各节点持续演化，从早期的提示工程，到覆盖提示词、技能、Agent 等所有非模型模块的马驹工程，再到 Agent 技术，低阶技术会被更高阶技术逐步覆盖，正如 AI 会逐步替代通用技能，当 AGI 拥有动态能力后，无需额外技能迭代支撑，最终会形成兼

具通用性与落地实用性的统一架构，成为下一个技术弹射点。当前 Agent 领域创新主体边界尚未明确，AI 技术迭代速度较快：谷歌大脑联合创始人近期发布支持多模态、实时打断的大模型；阿里发布采用 MOE 多专家模式的 33.6 版本 Rim 大模型，可实现随时打断、简单问题调用小参数、复杂问题调用大参数的降本互动效果。同时 Agent 落地需匹配真实工作流中的权限、安全等要求，传统软件、SaaS 厂商对复杂流程的 know-how 积累更深，模型厂商也在持续扩张业务边界，两类主体的业务边界尚未明确划定。当前大模型指数型增长已经结束，但在多模态、token 成本优化层面仍有较大发展空间；AI 产品与互联网产品零边际成本特性不同，每新增一个用户就会产生额外运算成本，需相关技术创新支撑降本。当前 IDE 集成调试工具、可观测性一体化等 Agent 相关配套能力大厂已落地，但出于商业利益考量未开源，例如 Cloud Code 已实现 Agent 架构相关功能，但出于商业考量将功能绑定，用户权限较弱；大模型厂商、云厂商已在金融、电信运营商、客服、供应链等领域通过驻场工程师形式落地 Agent 相关功能，但未形成通用开源架构，行业有待能打通现有技术、编排整合全链路能力的主体出现，推动通用架构落地。技术演进为渐进式路径；当前创新主体边界尚未明确；大厂已实现相关技术但未对外开源。

Q&A

Q: Agent 框架的演进方向和范式是什么？

A: Agent 架构正从单体智能向协作生态演进。单 Agent 架构通过引入状态机、规则引擎与符号推理等混合架构提升精确性与可靠性，解决荒谬决策与安全问题；多 Agent 生态则依托编排器协调，采用分层协作、网状协作与持续交接三种模式，形成类似综合医院联盟的网络体系，有效缓解上下文污染、规则冲突、可调试性差、扩展断层及容错性低等瓶颈。OpenCloud 与 Hermes 代表单 Agent 阶段的关键弹射点，未来将向编排层加多 Agent 协作网络发展，最终实现与人类生产工作环境深度融合的架构形态。

Q: 为什么 Agent 架构需要从单 Agent 演进到多 Agent 协作网络?

A: 单 Agent 架构存在任务丢失、安全性不足、可监测性弱、可调试性差及记忆混乱等问题，例如龙虾记忆未分层导致逻辑冲突，Hermes 虽优化记忆分层与 skill 自我进化能力，但仍属通用架构，难以覆盖医疗、法律等专业领域。多 Agent 协作网络通过编排器统筹多个专业 Agent，模拟综合医院联盟运作，解决上下文注意力衰减、规则冲突、上游幻觉在下游放大等缺陷，显著提升复杂任务处理的可靠性、扩展性与容错能力。

Q: LangGraph 云图谱实现的主要功能是什么？

A: LangGraph 构建了编排器的雏形，能够清晰记录 Agent 间任务授权、执行路径与结果返还的全流程，提供权限管理、操作日志与历史追溯能力，接近未来编排层所需的规则大脑，增强任务处理的可审计性与可调试性，为多 Agent 协作提供结构化调度基础。

Q: 编排层加多 Agent 架构对计算资源的需求有何影响？
A: 该架构将显著提升对云上 GPU 实例、事件总线、向量检索及边缘计算节点的需求，驱动企业持续采购云服务、英伟达等加速硬件及消息数据中间件。通信基础设施重要性凸显，参考黄仁勋收购玻璃厂布局光纤产能，以支撑多 Agent 间高频状态传递与网络协同，硬件与通信成为关键支撑环节。

Q: 未来的编排层加多 Agent 架构与 OpenCloud、Hermes 等前期技术是渐进关系还是替代关系？
A: 属于渐进演化关系。技术节点持续凝结升维，提示工程、Agent、MCP 等能力被更高维度架构整合吸收。当 Agent 具备动态 skill 进化能力后，预制 skill 需求将减弱，架构将向通用且高效的方向收敛，形成如鲤鱼般可广泛适配多场景的成熟形态，而非简单替代前期技术。

Q: 在 Agent 落地过程中，掌握工作流 know-how 的传统软件公

司或 SaaS 公司是否会比模型公司发挥更大作用?
A: 当前技术边界尚未清晰划定。模型公司在多模态、token 成本优化等领域持续创新；同时，Cloud Code、OpenAI 等通过驻场工程师将 Agent 深度集成至金融、电信、客服、供应链等垂直领域工作流，SaaS 厂商在权限设计、流程合规与领域知识方面具备优势。但因商业壁垒导致通用架构未开源，需整合者突破，创新主体可能向兼具技术理解与行业 know-how 的中厂及垂直领域企业倾斜。

Q: Hermes 相比龙虾的主要技术进步体现在哪些方面?
A: Hermes 实现记忆分层并赋予 skill 自我进化能力，通过用户交互后的反思机制与世界知识库持续优化技能，使 Agent 处理能力趋近呼吸般自然；而 龙虾虽引入记忆功能，但未分层易导致混乱，skill 为预制状态且存在 skill 中毒风险，Cloud Code 后续推出 8 万+ skill 评分系统以应对该问题。

Q: 未来 Agent 架构与人类生产生活完全结合时应具备哪些核心特征?
A: 需具备五大特征：清晰的编排层；原生支持多端协作；与开放协议深度绑定；优秀的开发者体验与可观测性；Agent 动态性。