1.
Token 经济学与 MaaS 业务基本定义
Token 定位：Token 是全新商业模式的计量单位，生产端以大规模 GPU 算力集群为底座，由大模型厂商生成。
Token 分销/代理平台本质：属于流通端商业环节，也被称为 token 中转站、token 聚合平台、token 运营，核心模式是向上游大模型厂商批量采购 tokens，加价后卖给下游客户，赚取中间利差。
MaaS（模型即服务）定义：在 token 分销基础上叠加模型调优、模型选型、场景定制化等增值服务，整体市场收入由 token 分销利差收入+增值服务收入两部分组成，和此前的 SaaS（软件即服务）模式逻辑相似，仅服务核心从软件变为大模型。
2.
Token 分销产业链与核心优势
产业链角色：分为三个核心环节，上游是 AI 大模型厂商（token 供给方，代表包括智谱、Kimi、字节豆包、阿里云通义千问、腾讯混元等），中间层是代理平台，下游是终端用户，整体逻辑和此前的流量运营、广告运营模式相似。
Token 分销业务属性：属于典型轻资产服务，不需要 GPU、服务器等重资产投入，仅需要上游采购渠道和下游客户资源即可开展，成本端仅包含平台开发费用，成本压力较小。
Token 分销平台核心价值：
网络层面：解决国内开发者、出海商家调用海外顶级模型的网络接入问题。
接口层面：通过统一的 key 和接口，帮助 B 端开发者实现多模型便捷调用、自由切换，无需单独对接不同厂商的差异化接口。
支付层面：提供合法合规的支付结算方式，支持人民币、微信、支付宝、B 端对公支付等。
成本层面：以大规模采购拿到上游低价批发额度，对接下游中长尾客户时价格仍低于官方定价，实现买卖双方成本优化。
当前 MaaS 市场主要参与者：官方直接分销渠道包括阿里云、腾讯云，主要服务大客户；中介聚合平台代表包括字节火山引擎、阿里云、硅基流动等，主要服务中长尾客户。
3.
Token 市场需求与增长驱动
整体需求爆发情况：
自 2026 年 3-4 月 AI Agent 落地以来，token 调用量急速上升：全球最大 API 聚合平台 OpenRouter 的调用量从 2025 年的每周 5 万亿左右增长至 2026 年 5 月的每周 20 万亿，增长 300%；阿里云 2026 年 5 月的日均 token 使用量较 4 月初增长 5 倍。
2026 年 3 月中国发展高层论坛披露，截至 2026 年 3 月中国日均 token 消耗量突破 140 万亿，两年增长超 1000 倍，增长核心动力来自垂类 Agent 全面落地，B 端、企业自有 Agent 平台搭建，以及短剧、漫剧、营销、游戏、电商等场景的需求爆发。

国产大模型出海需求快速增长：2026 年一季度 OpenRouter 平台中国模型调用量首次超越美国；截至 2026 年 5 月 7 日的周度榜单中，腾讯混元调用量位居榜首，前五、前十、前 20 名中分别有 2 款、6 款、9 款国产大模型。
中国企业端 MaaS 市场 token 调用量快速攀升：2025 年上半年日均调用量为 10-20 万亿，2025 年下半年增长至 30-50 万亿，需求主要来自泛互联网行业，集中在游戏、娱乐、教育、办公、短剧、市场营销、数据处理、数据分析等场景。
核心增长驱动因素：
供需两端增长：上游国产大模型能力提升、出海意愿增强，下游 AI 在多场景渗透加强，token 需求极速膨胀，中间代理运营是商业生态的必要环节。
全球 AI 资源分布不均：催生跨境分发需求，国内商家调用海外模型、海外用户调用中国模型、中国大模型出海均需要中介平台作为枢纽。
企业 AI 建设门槛较高：除基础 token 调用外，模型选型、调优、提示词使用等环节存在隐性成本，衍生增值服务需求。
大模型行业缺乏统一标准：不同厂商的请求格式、数据限制、错误代码均不同，开发者多模型对接的时间、人力成本高，统一接入的平台价值凸显。
4.
Token 分销盈利模式
转售利差模式：中介平台大规模采购上游模型通常可拿到 6-7 折的批发价，向下游中长尾客户售卖时价格为官方定价的 8-9 折，整体利润空间约 20%；该模式下分为海外模型进国内、国内模型出海两个方向，国内模型批发折扣更低，利润率更高，且业务轻资产属性支持通过高周转放大利润规模。
技术溢价模式：中介平台通过自研推理加速技术，在采购 token 数量不变的情况下提升推理效率，压缩成本获取超额毛利率；例如硅基流动自研 OneDiff、SiliconLLM 两款加速模型，若将文生视频模型效率提高 3 倍，同等 token 采购量下成本可缩减至原来的 1/3，额外收益归平台所有。
场景增值服务模式（MaaS 服务）：在基础 token 转售之外，针对客户具体场景提供模型选型、模型调优、提示词优化、场景搭建、应用开发等附加服务；短剧、漫剧、游戏、电商等场景的中长尾客户 token 消耗需求真实可持续，且无能力自行搭建相关体系，该类服务需求空间较大。
5.
市场规模预测与投资方向
市场规模预测：
IDC 乐观假设下，2026 年中国 MaaS 市场营收规模将达到 186 亿人民币，2030 年预计较 2026 年实现 10 倍增长。
团队保守测算：当前中国日均 token 消耗量 120 万亿，其中 B 端中长尾客户占比 10%，对应日均消耗 12 万亿；剔除直接对接厂商的大客户后，适合分销的子市场占比 30%，对应日均均可分销 token 量 3-4 万亿，年化约 1300 万亿；按 10 元/百万 token 的均价计

算，年化分销市场规模约 130 亿元；远期随着 token 消耗量、B 端占比、分销市场占比提升，市场空间将进一步扩大。

投资关注方向：

具有优质模型能力的公司，代表包括阿里、腾讯、快手。

具备强场景、优质客源的公司，尤其是拥有优质海外客户资源，业务覆盖短剧、漫剧、游戏等 token 高消耗营销场景的企业。

AI 营销、AI 视频化领域积极布局 token 相关业务的公司，代表包括易点天下、蓝色光标等。